DÉCHIFFREMENT DE PROJET DE RECHERCHE

Projet 2 : Classification Hiérarchique en Monde Ouvert

Titre scientifique : *Open-World Hierarchical Cybersecurity Log Classification with Uncertainty-Aware Deep Learning*

---

1. De quoi s'agit-il ? (Le problème en mots simples)

Dans un centre de surveillance informatique (SIEM), des milliers de journaux d'événements (logs) sont générés chaque seconde par des serveurs, des pare-feux et des logiciels. Pour détecter les attaques, un système d'IA doit classer chaque journal (ex. : *« Tentative de connexion réussie »*, *« Fichier supprimé »*).

Le piège classique des IA traditionnelles (Monde Fermé) : Une IA classique est comme un élève qui a révisé un QCM avec 30 réponses possibles. Si on lui montre un événement totalement nouveau qu'il n'a jamais vu, il sera **forcé de choisir** une des 30 réponses connues. Il donnera donc une fausse réponse avec une assurance trompeuse.

La solution de ce projet (Monde Ouvert + Hiérarchie) : Nous voulons doter l'IA de deux compétences humaines fondamentales :

- **L'humilité (Monde Ouvert) :** Capacité de dire *« Je ne connais pas cet événement précis »* plutôt que d'inventer une mauvaise réponse.
- **Le bon sens hiérarchique :** Même si l'IA ne reconnaît pas l'action exacte, elle doit au moins reconnaître la famille globale (ex. : *« Je ne sais pas quelle action exacte a été faite sur le fichier, mais je suis sûr que cela concerne la gestion des FICHIERS »*).

> 📌 **Scénario Implicite #1 : Le Tri Courrier**
> *Imaginez un trieur de courrier. Il connaît les enveloppes de la "Banque A", "Banque B" et "EDF". Un jour, il reçoit une lettre d'une nouvelle banque "Banque C" (inconnue).*
> *• **IA classique (Monde fermé) :** Dit « C'est une lettre d'EDF ! » (Erreur grave).*
> *• **IA du Projet 2 (Monde ouvert) :** Dit « C'est un document Financier/Banque (Famille), mais la banque exacte m'est Inconnue ».*

2. Étapes du Projet Décortiquées Pas-à-Pas

Étape A : Structurer la Taxonomie (L'Arbre des Familles)

Les 30 catégories du jeu de données (SIEVE) sont regroupées sous des grands "parents" fonctionnels (Authentification, Fichiers, Réseau, Processus, Utilisateurs).

Exemple de structure :
• Famille Parent : `AUTHENTIFICATION`
  ├── Enfant 1 : `authentication-success` (Connexion réussie)
  └── Enfant 2 : `authentication-failed` (Connexion échouée)

Étape B : Masquer volontairement des classes (Simulation de l'Inconnu)

Pour tester si l'IA sait détecter l'inconnu, nous cachons volontairement une partie des données durant son entraînement. Par exemple, nous l'entraînons sur 24 classes et gardons 6 classes secrètes. Lors du test, nous lui présentons les 30 classes pour observer sa réaction face aux 6 classes "inconnues".

Étape C : L'Architecture à Double Tête (L'Apprentissage Hiérarchique)

Nous utilisons un modèle d'apprentissage profond de type Transformer (comme BERT ou DeBERTa). Au sommet de ce modèle, nous branchons deux sorties ("têtes") :

- **Tête 1 (Niveau Famille) :** Prédit la catégorie globale (ex: *Fichier*).
- **Tête 2 (Niveau Précis) :** Prédit la classe spécifique (ex: *file-deleted*).

Une règle de cohérence est imposée : la classe fine doit obligatoirement être un enfant légitime de la famille prédite.

Étape D : Le Mécanisme de Rejet et de Mesure d'Incertitude

Avant de donner son verdict final, l'IA calcule son **degré de doute** (score d'incertitude). Si son doute dépasse un certain seuil, le mécanisme de rejet s'active.

> 📌 **Scénario Implicite #2 : La Détection d'un Log d'Attaque Inédit dans le SIEM**
> *Un pirate utilise un nouvel outil de malware qui génère un log système jamais rencontré jusqu'ici.*
> *1. Le journal entre dans l'IA.*
> *2. La tête Famille identifie avec 95% de certitude que cela concerne un PROCESSUS.*
> *3. La tête Précise hésite fortement entre `process-started` (30%) et `process-error` (25%).*
> *4. **Score d'incertitude élevé détecté !***
> *5. **Résultat émis :** Alerté le SOC avec l'étiquette « Événement Inconnu [Famille probable : Processus] ». L'analyste humain sait immédiatement où chercher sans être induit en erreur.*

3. Résumé Visuel du Processus de Décision

Étape	Action du Système	Exemple d'issue
1. Entrée	Analyse du texte brut du log par BERT/DeBERTa	`"User admin session terminated abruptly"`
2. Evaluation Famille	Prédiction de la famille parente avec forte confiance	Famille : `USER / SESSION` (Confiance 98%)
3. Evaluation Incertitude	Calcul de la distance/doute sur la classe précise	Score d'incertitude : **Élevé (Hors-limite)**
4. Décision Finale	Activation du filtre Monde Ouvert (Rejet)	**"Événement Inconnu (Famille: User/Session)"**

4. Les Attentes et Livrables du Projet

À la fin de ce projet de recherche, voici exactement ce qui est attendu et ce que le système doit prouver :

1. **Conserver une excellente précision sur le connu :** Le modèle doit continuer à classer très exactement les événements qu'il connaît (Maintenir un F1-Score élevé sur les classes fermées).
2. **Taux d'erreur contraint sur l'inconnu :** Capacité à détecter au moins 95% des événements inconnus sans rejeter par erreur des événements connus (Mesuré par AUROC / OSCR).
3. **Utilité opérationnelle en sécurité :** En cas d'inconnu, le système doit au moins fournir la famille parente exacte dans la grande majorité des cas pour guider l'analyste de sécurité.
4. **Robustesse au bruit :** Le système doit conserver ses capacités même lorsque les logs contiennent des bruits lexicalement complexes (Vérifié sur les versions SIEVE_00 à SIEVE_05).