Classification hiérarchique de logs SIEM en monde ouvert

Détection d'événements inconnus par apprentissage profond et estimation d'incertitude.

30 classes **9** familles **5** rotations **12** modèles



Présenté par

Mouhamadou Madeniyou SALL

Khadim MBAYE

Cours · Classe

NLP — Natural Language Processing

DIC 3 IABD

```
output_0.log — SIEVE_00

[error] user alice: authentication failure … → authentication-failed
kernel: unexpected eBPF program … → INCONNU · famille process
```

Plan de la présentation

01
Contexte et problématique
Le SIEM, les logs, le problème du monde fermé, la question de recherche et les objectifs.

02
État de l'art
NLP pour la cybersécurité, classification hiérarchique, détection open-set.

03
Données et méthode
SIEVE, taxonomie, prévention des fuites de templates, environnement d'exécution.

04
Conception
Pipeline, architecture à deux têtes, protocole open-set, scores de familiarité.

05
Résultats
E1 à E4, analyse des confusions, synthèse par rapport aux cibles.

06
Limites et conclusion
Ce que le protocole ne prouve pas, réponse à la question, perspectives.

Question traitée

Comment classer un événement dans une taxonomie de sécurité tout en reconnaissant qu'il n'appartient à aucune des classes apprises ?

Contexte et problématique

Contexte et problématique

Un modèle fermé doit toujours choisir une classe, même lorsqu'aucune ne correspond à l'événement observé.

01 Contexte : les logs SIEM

02 Anatomie d'un log SIEVE

03 Le problème du monde fermé

04 Problématique et hypothèse

05 Objectifs

Contexte : les logs SIEM

Un SIEM collecte les journaux de pare-feu, de serveurs et d'applications. La classification transforme un texte brut en catégorie exploitable par l'analyste.

30
catégories dans SIEVE

35 000
logs par version

210 000
logs au total



Le volume n'est pas le principal obstacle : c'est l'interprétation. Un log mal classé peut orienter l'analyste vers une fausse piste ou masquer un événement nouveau.

Volume

Six versions, 35 000 logs chacune, trente classes équilibrées.

Variabilité

IP, utilisateur, chemin et date changent à chaque ligne.

Nouveauté

Une classe peut apparaître au test sans avoir été vue à l'entraînement.

> La classification est le premier maillon de la chaîne d'analyse d'un SOC.

Anatomie d'un log SIEVE

Un log est un texte structuré par des champs. Le label dépend de l'action, pas des valeurs : IP, utilisateur, chemin et date changent à chaque ligne.

output_0.log — SIEVE_00 · p = 0,0

```
[Wed Nov 03 19:30:11 1976] [error] [client 217.121.56.73] user clarkesummer: authentication failure for "/at/challenge.png/pass": Password Mismatch
[Sat May 21 08:27:17 1988] [error] [client 195.255.99.164] user alicekelly: authentication failure for "/age/evidence.mp3/be": Password Mismatch

— même classe, même template, valeurs différentes

[SIEVE_03 · p = 0,3] :Mismatch [shake] [client for] user lori8972.3.117.167 " failure : "/raise/little.mov/Tue Mar 18 20:20:17 1986authenticationerror Passwor…

[SIEVE_05 · p = 0,5] :forauthentication [failure] /authority/car.wavhsandoval 214.18.6.71] user /: client Mismatch Thu Dec 07 03:54:44 2006 "[Password[]air " e…
```

Extraits réels des fichiers **output_0.log** à **output_0.5.log**, tronqués.

Champs observés

Date	[Wed Nov 03 …]
Niveau	[error]
Client	217.121.56.73
Acteur	clarkesummer
Action	authentication failure
Objet	/at/challenge.png/pass

Template sous-jacent

```
[DATE] [error] [client IP] user USER: authentication failure for "PATH": Password Mismatch
```

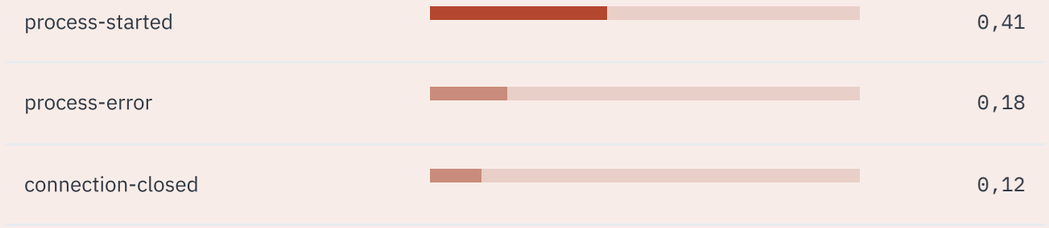
440 templates pour 30 classes · 1 167 logs par classe en moyenne.

Le problème du monde fermé

Un classifieur fermé produit toujours une distribution sur les classes connues. Il doit choisir, même si aucune ne correspond à l'événement observé.

Monde fermé

```
[kernel] unexpected eBPF program attached to socket …
```



Le modèle ne signale pas son ignorance. L'analyste reçoit une étiquette fausse, avec une confiance de 41 %.

Monde ouvert

Événement inconnu

famille probable : **process** · confiance famille 0,62

Le rejet oriente l'événement vers une analyse humaine. La famille donne un point de départ à l'analyste.

> Dans un SIEM, une réponse fausse avec 41 % de confiance est plus dangereuse qu'un rejet explicite.

Problématique et hypothèse

Comment classer un événement dans une taxonomie de sécurité tout en reconnaissant qu'il n'appartient à aucune des classes apprises ?

À l'entraînement, le modèle voit **K classes connues**. À l'inférence, un log x peut venir de K ou d'une classe inconnue **U**. Le système doit classer si $x \in K$, rejeter si $x \in U$, et si possible indiquer la famille.

Hypothèse H1

Une architecture hiérarchique, un score de familiarité et un seuil calibré réduisent les erreurs forcées sur l'inconnu sans dégrader la classification du connu.

Précision

Un modèle plus précis sur le connu est-il nécessairement trop confiant sur l'inconnu ?

Hiérarchie

La structure famille → classe aide-t-elle à décider, ou ajoute-t-elle de la complexité ?

Robustesse

Que reste-t-il des performances quand les logs sont bruités ?

Le projet évalue séparément la justesse fine, la justesse famille, la détection des inconnus et la robustesse.

Objectifs

Objectif général

Concevoir et évaluer un classifieur de logs capable de classer le connu, de rejeter l'inconnu et de rester utile à l'analyste.

OS1	Organiser les 30 classes en neuf familles fonctionnelles.
OS2	Simuler l'inconnu avec cinq rotations de six classes masquées.
OS3	Concevoir une double tête famille / classe avec cohérence.
OS4	Comparer cinq scores de familiarité et calibrer un seuil.
OS5	Évaluer en fermé, en open-set et sous bruit, avec une vue stricte.

Cibles du cahier des charges

- F1 élevé sur le connu
- 95 % des inconnus détectés, sans rejeter les connus
- Famille exacte pour guider l'analyste
- Robustesse de SIEVE_00 à SIEVE_05

Ces cibles servent de grille de lecture aux résultats, y compris lorsqu'elles ne sont pas atteintes.

Classification

Macro-F1, accuracy fine, accuracy famille, distance taxonomique.

Détection

AUROC, AUPR, OSCR, taux d'acceptation des inconnus.

Robustesse

SIEVE_00 à SIEVE_05, à seuil fixé.

Vocabulaire : closed-set = toutes les classes sont connues ; open-set = des exemples peuvent appartenir à des classes jamais vues.

État de l'art

État de l'art

Les transformers savent lire un log, la hiérarchie le structure, les scores open-set savent douter. Rarement les trois ensemble.

01 NLP pour la cybersécurité

02 Classification hiérarchique

03 Détection open-set

04 Positionnement du projet

Trois axes de recherche

Chaque courant résout une partie du problème. Aucun ne fournit à lui seul un système complet pour les logs SIEM.

NLP pour la cybersécurité

Pré-entraînement spécialisé : vocabulaire, entités et syntaxe des logs.

`SecureBERT` `CySecBERT` `LogBERT`

Apport	Sémantique robuste
Limite	Monde fermé, plat

Dans le projet : DistilBERT, 66 M paramètres.

Classification hiérarchique

Taxonomies, cohérence parent-enfant, régularisation des labels.

`HLAST` `Corbelle` `Pan & Wu`

Apport	Structure, information famille
Limite	Pas de rejet explicite

Dans le projet : Double tête famille / classe, $\lambda = 0{,}5$.

Détection open-set

Scores de familiarité, distance en embedding, ensembles, seuils calibrés.

`MSP` `Energy` `Prototypes` `MC-Dropout`

Apport	Rejet des inconnus
Limite	Ignore la taxonomie

Dans le projet : Cinq scores et un seuil calibré.

Un système qui combine les trois, sur des logs SIEM, avec une évaluation anti-fuite.

Position du projet

Positionnement du projet

La littérature couvre séparément les trois briques. Le projet les assemble et évalue l'ensemble sur SIEVE.

Travail	Approche	Limite pour le projet
SecureBERT 2022	NLP cyber	Monde fermé, classification plate
CySecBERT 2022	NLP cyber	Pas de tête hiérarchique
LogBERT 2021	NLP cyber	Détection d'anomalies, pas de classes
HLAST 2025	Hiérarchie	Aucun rejet open-set
Corbelle 2024	Hiérarchie	Pas de seuil de rejet
Pan & Wu 2025	Hiérarchie	Généraliste, hors SIEM
Prasetyo 2025	Open-set	Pas de taxonomie
Projet 2 — SIEVE	Les trois	Évaluation stricte, sans fuite de templates

Références complètes en annexe B.

Contribution

Aucun travail, à notre connaissance, ne combine :

1. hiérarchie famille → classe ;
2. rejet explicite de l'inconnu ;
3. robustesse au bruit lexical ;
4. sur SIEVE, avec split par template.

Éléments repris

Encodeur pré-entraîné, double tête hiérarchique, scores de familiarité et seuil calibré.

Données et méthode

Données et méthode

Six versions, trente classes et 440 templates. Le protocole doit aussi éviter les fuites entre entraînement et test.

01 Le jeu de données SIEVE

02 Taxonomie : 30 classes, 9 familles

03 Prévention des fuites

04 Bibliothèques et environnement

Le jeu de données SIEVE

Six versions du même corpus, du propre (p = 0) au bruité (p = 0,5). Le modèle s'entraîne sur la version propre et affronte les cinq autres au test.

Version	p	Rôle	Lignes	Similarité	Chars
SIEVE_00	0,0	Référence	34 996	1,000	150,9
SIEVE_01	0,1	Robustesse	35 000	0,895	155,0
SIEVE_02	0,2	Robustesse	35 000	0,867	159,6
SIEVE_03	0,3	Robustesse	35 000	0,847	164,1
SIEVE_04	0,4	Robustesse	35 000	0,830	167,6
SIEVE_05	0,5	Robustesse	35 000	0,808	172,8

30
classes

440
templates

35k
logs / version

210k
logs au total

Point de vigilance

Les fichiers fournis contiennent 35 000 lignes, et non 100 000 comme annoncé dans le descriptif général. Tous les résultats portent sur ce corpus.

La similarité moyenne mesure la proximité textuelle avec la version propre.

Référence

SIEVE_00, p = 0 : entraînement et test fermé.

Robustesse

SIEVE_01 à 05 : test uniquement, seuil figé.

Dégradation

Similarité 1,000 → 0,808 ; longueur 151 → 173 caractères.

SIEVE_00 sert à l'entraînement ; **SIEVE_01 à 05** servent uniquement à mesurer la robustesse.

Taxonomie (1/2) : cinq familles

SIEVE ne fournit pas de hiérarchie. Les 30 classes sont regroupées en neuf familles fonctionnelles, de deux à cinq enfants chacune.

Famille	Classes enfants	n
authentication	`authentication-failed` · `authentication-success`	2
connection	`connection-closed` · `connection-failed` · `connection-opened`	3
directory	`directory-changed` · `directory-created` · `directory-deleted`	3
file	`file-action-failure` · `file-deleted` · `file-modification` · `file-read` · `file-write`	5
http	`http-request-failure` · `http-request-success`	2

Règle de cohérence

Un log est d'abord classé dans une famille, puis dans une classe enfant de cette famille. La classe fine ne peut jamais contredire la famille.

Les quatre familles restantes sont présentées sur la slide suivante.

Taxonomie (2/2) : quatre familles

Les quatre dernières familles complètent la taxonomie. Certaines frontières restent ambiguës et sont documentées comme telles.

Famille	Classes enfants	n
network_security	`ids-alert` · `network-filtered` · `network-traffic`	3
process	`process-ended` · `process-error` · `process-info` · `process-shutdown` · `process-started`	5
system	`database-operation` · `hardware-monitoring` · `system-configuration-changed`	3
user	`user-creation` · `user-deletion` · `user-logout` · `user-session-open`	4

Bilan

9 familles, 30 classes, 2 à 5 enfants par famille. La taxonomie est une construction fonctionnelle, non fournie par SIEVE.

Cas ambigus

`user-logout` ⇔ `connection-closed` et `directory` ⇔ `file` restent discutables.

Cette taxonomie devrait être validée par un expert SIEM avant d'être utilisée en production.

Prévention des fuites de templates

Deux variantes d'un même template ne doivent pas être séparées entre entraînement et test.
Sinon, le score mesure la mémorisation d'une structure, pas la généralisation.

Split aléatoire



Les variantes d'un même template tombent des deux côtés de la frontière.

Split par groupe



Chaque groupe reste entier : le test contient des templates jamais vus.

01

TF-IDF par classe

Vectorisation des logs, classe par classe.

02

KMeans · k = templates

440 groupes reconstruits.

03

Split 60 / 20 / 20

Au niveau du groupe, jamais de la ligne.

440

groupes reconstruits

0

groupe partagé (strict)

ARI moyen 0,883 · médiane 0,991.

Vue stricte et vue complète

19 classes ont assez de groupes pour un split par template. **11 classes** n'en ont pas : une fuite résiduelle reste possible.

`strict · 19 classes` `all · 30 classes`

Découpage retenu



21 185	6 853	6 958
train	validation	test

Le nombre de templates par classe est supposé connu : le clustering sert à retrouver les groupes, pas à choisir k.

Bibliothèques et environnement d'exécution

Le projet tient sur un notebook Colab et une Tesla T4 gratuite. Douze modèles sont entraînés en 42 minutes.

Bibliothèque	Version	Usage
PyTorch	`2.14.1 + cu130`	Entraînement, AMP, inférence
Transformers	`5.22.1`	DistilBERT, tokenizer
scikit-learn	–	TF-IDF, KMeans, métriques
pandas · numpy	–	Données, calcul vectoriel
matplotlib · scipy	–	Figures, tests statistiques

Hyperparamètres

`max_len 96` `batch 64` `3 époques` `lr 5e−5` `warmup 6 %` `λ 0,5` `5 passes MC` `seed 42`

Google Colab · free tier

Tesla T4

16 Go de VRAM · sans frais

GPU	Tesla T4 · 16 Go
RAM	12,7 Go · 2 vCPU
Python	3.13.16
Précision	AMP · float16

42 min
de bout en bout

12
modèles entraînés

DistilBERT : 66 M paramètres, 6 couches, 768 dimensions. Environ 3 minutes par modèle.

Notebook **Open_World_SIEVE_nb.ipynb** · configuration dans `outputs/config.json` · journal dans `outputs/recap.log`.

Conception

Conception

Une représentation partagée, deux têtes, une contrainte de cohérence, cinq scores et un seuil calibré.

01 Pipeline de traitement

02 Architecture du modèle

03 Protocole open-set

04 Scores et calibration

Pipeline de traitement

Un seul flux, du fichier texte jusqu'à la décision « classe connue » ou « événement inconnu ».

01
Charger
6 versions, 35k lignes, nettoyage

02
Grouper
TF-IDF + KMeans, 440 templates

03
Séparer
60 / 20 / 20 par groupe

04
Taxonomie
30 classes → 9 familles

05
Encoder
DistilBERT, 96 tokens, mean pool

06
Entraîner
2 têtes + cohérence, λ = 0,5

07
Décider
5 scores, seuil τ, rejet

Entraînement

SIEVE_00 uniquement. 24 classes connues par rotation, 6 masquées. Trois époques, sans early stopping : le dernier état est conservé.

Évaluation

SIEVE_00 à 05, plus les 6 classes inconnues de chaque rotation. Le seuil est calibré sur la validation propre, puis figé pour tous les tests.

```
[kernel] unexpected eBPF program …   s(x) = 0,41 < τ = 0,58
```

INCONNU · famille process

Anti-fuite

440 groupes, split par template, jamais par ligne.

Déséquilibre

1 167 logs par classe en moyenne, 30 classes.

Répétabilité

Seed 42, 5 rotations, configuration versionnée.

Chaque étape écrit ses artefacts dans `tables/`, `figs/` et `recap.log`.

Architecture du modèle

Une représentation partagée et deux têtes : une famille et une classe fine. La perte impose la cohérence entre les deux niveaux.



Fonction de perte

$$L = L_{fine} + L_{fam} + \lambda \cdot L_{coh}$$

$$L_{coh} = -\log \Sigma_k \, p_k \cdot q_{\varphi(k)}$$

φ(k) est la famille de la classe k. Le terme est minimal quand les deux têtes sont d'accord.

λ	Cohérence observée	Baseline
0,5	98,2 %	plat · 1 tête

Pourquoi le mean pooling

Le masque d'attention exclut les tokens de padding. La moyenne des états cachés donne un vecteur unique, plus stable qu'un simple [CLS] sur des logs courts et bruités.

La baseline plate utilise le même encodeur, une seule tête et aucun terme de cohérence.

Protocole open-set : rotations

À chaque rotation, 6 des 30 classes sont retirées de l'entraînement et deviennent les inconnues du test. Cinq rotations disjointes couvrent les 30 classes.

Rotation	Classes inconnues	n
Rotation 1	directory-deleted · file-action-failure · http-request-failure · ids-alert · process-shutdown · user-deletion	6
Rotation 2	authentication-failed · connection-opened · file-read · http-request-success · process-started · user-logout	6
Rotation 3	authentication-success · connection-closed · database-operation · file-modification · file-write · process-info	6
Rotation 4	connection-failed · network-filtered · process-error · system-configuration-changed · user-creation · user-session-open	6
Rotation 5	directory-changed · directory-created · file-deleted · hardware-monitoring · network-traffic · process-ended	6

Pourquoi cinq rotations

Un seul découpage dépendrait de la difficulté des classes masquées. Cinq rotations disjointes donnent une moyenne et un écart-type, et couvrent chaque classe une fois.

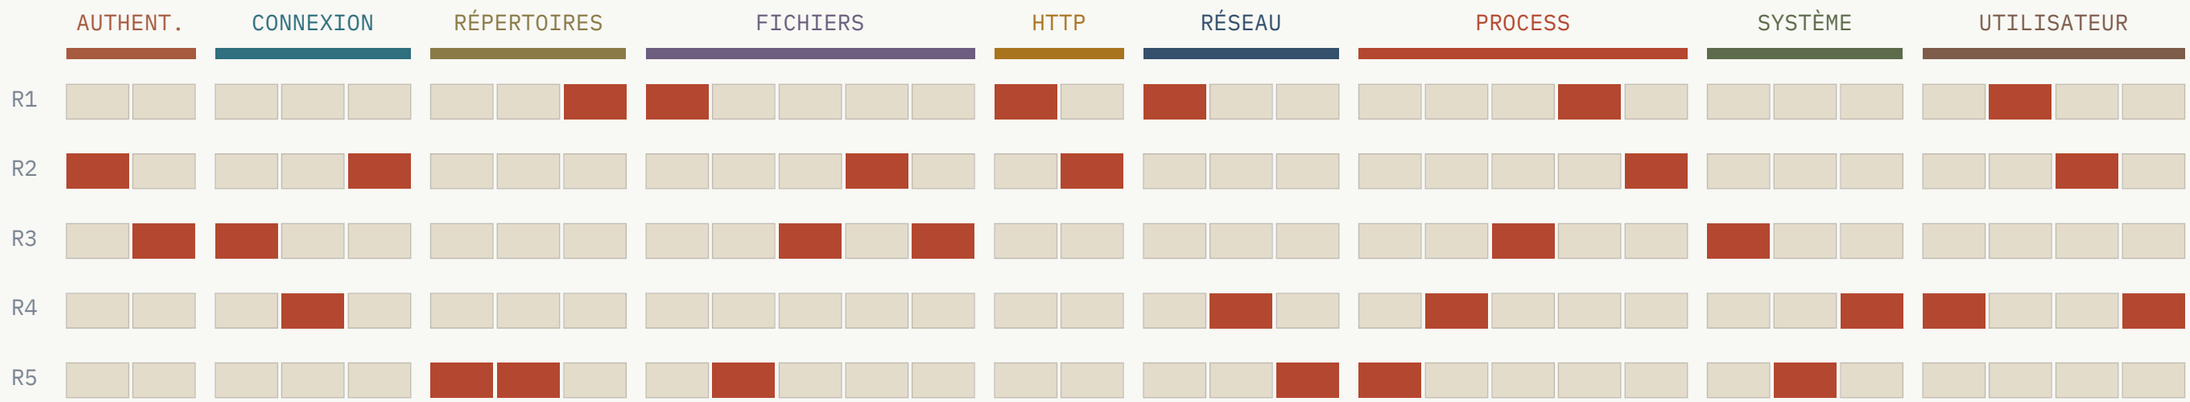
La couverture complète des 30 classes est présentée sur la slide suivante.

Protocole open-set : couverture

Chaque colonne correspond à une classe, chaque ligne à un entraînement sans les six classes marquées.

classe inconnue classe connue

5 rotations · 30 classes · 6 inconnues par rotation



30
classes couvertes

6
inconnues par rotation

5
rotations disjointes

Chaque classe est inconnue exactement une fois : le résultat ne dépend pas d'un choix particulier de classes cachées.

Scores de familiarité et calibration

Un classifieur ne fournit pas naturellement un score d'inconnu. Cinq scores sont comparés, puis un seuil est calibré sur la validation.

Méthode	Calcul	Ce qu'elle mesure
MSP	$\max_k p_k$	Confiance dans la meilleure classe
Energy	`logsumexp(logits)`	Niveau global d'activation
Prototypes	$\max_c \cos(z, \mu_c)$	Proximité aux représentations de classe
MC-Dropout	$-H(\bar{p})$ sur 5 passes	Stabilité de la prédiction
Hiérarchique	$\max_k p_k \cdot q_{\varphi(k)}$	Accord entre famille et classe

Calibration

τ = 5e percentile des scores connus en validation. Le seuil garde 95 % des connus et est recalculé par rotation et par méthode.

$s(x) \geq \tau \rightarrow$ classe connue · $s(x) < \tau \rightarrow$ événement inconnu

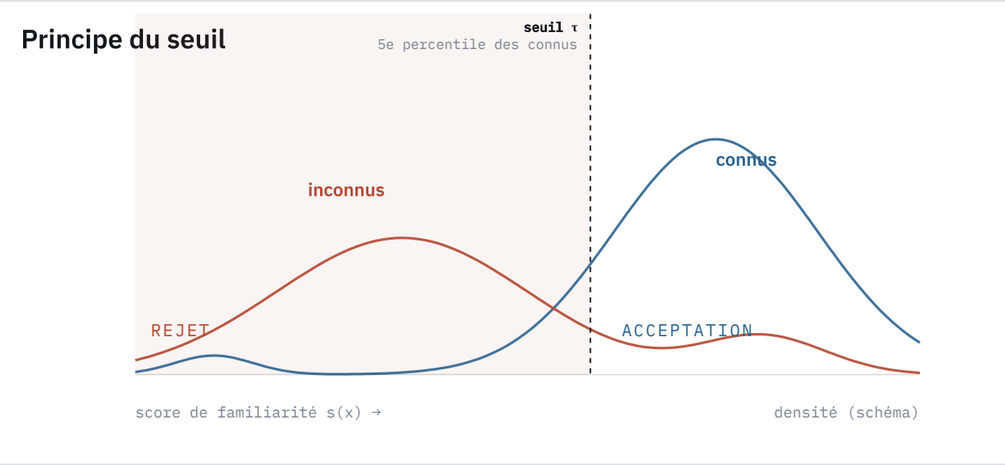


Schéma de principe. Les scores sont orientés : plus haut = plus familier.

> Le seuil ne garantit pas que les inconnus seront rejetés : c'est l'objet de E2.

Résultats

Résultats

Quatre expériences, quatre lectures : classification fermée, détection open-set, qualité hiérarchique et robustesse.

01 E1 · classification fermée

02 E2 · détection open-set

03 E3 · qualité hiérarchique

04 E4 · robustesse

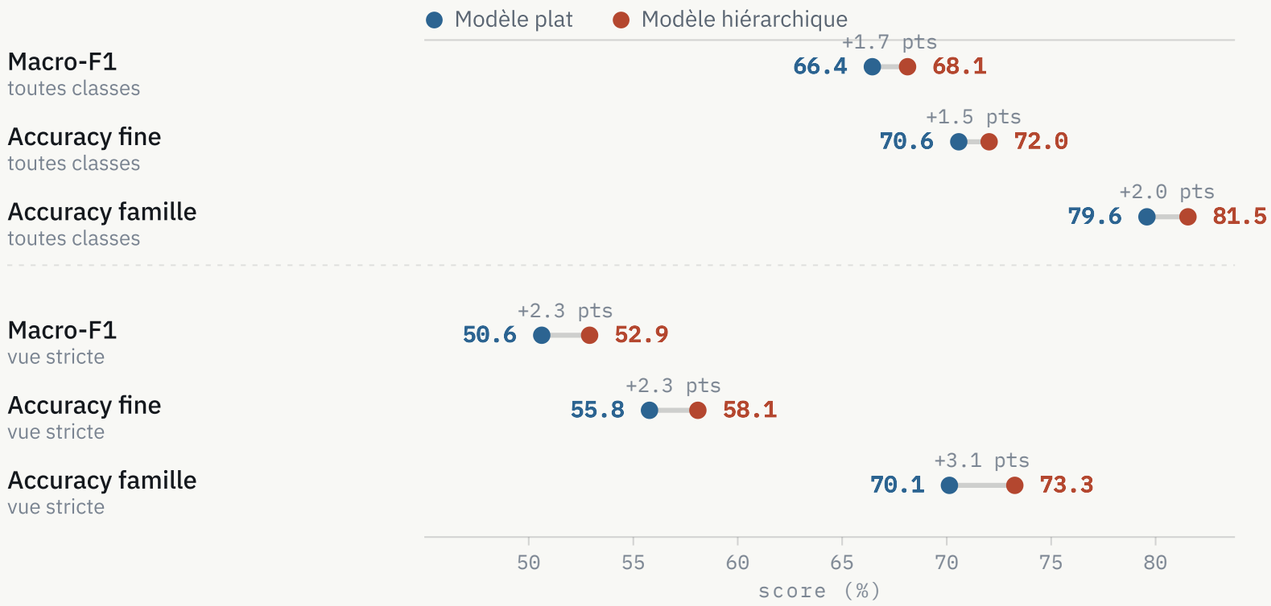
05 Synthèse

E1 — Classification fermée

Sur SIEVE_00, avec les 30 classes connues, le modèle hiérarchique dépasse le modèle plat sur les trois métriques, dans la vue complète comme dans la vue stricte.

FERMÉ — 30 CLASSES CONNUES

E1 · SIEVE_00



Gain du modèle hiérarchique

Accuracy fine	72,0 %	70,6 %
Macro-F1	0,681	0,664
Accuracy famille	81,6 %	79,6 %

Colonne 1 : hiérarchique. Colonne 2 : plat.

Point de vigilance

La vue stricte perd 15 points de F1. L'ECE reste à 0,21 : le modèle est trop confiant.

+1,4 pt
accuracy fine

+1,7 pt
Macro-F1

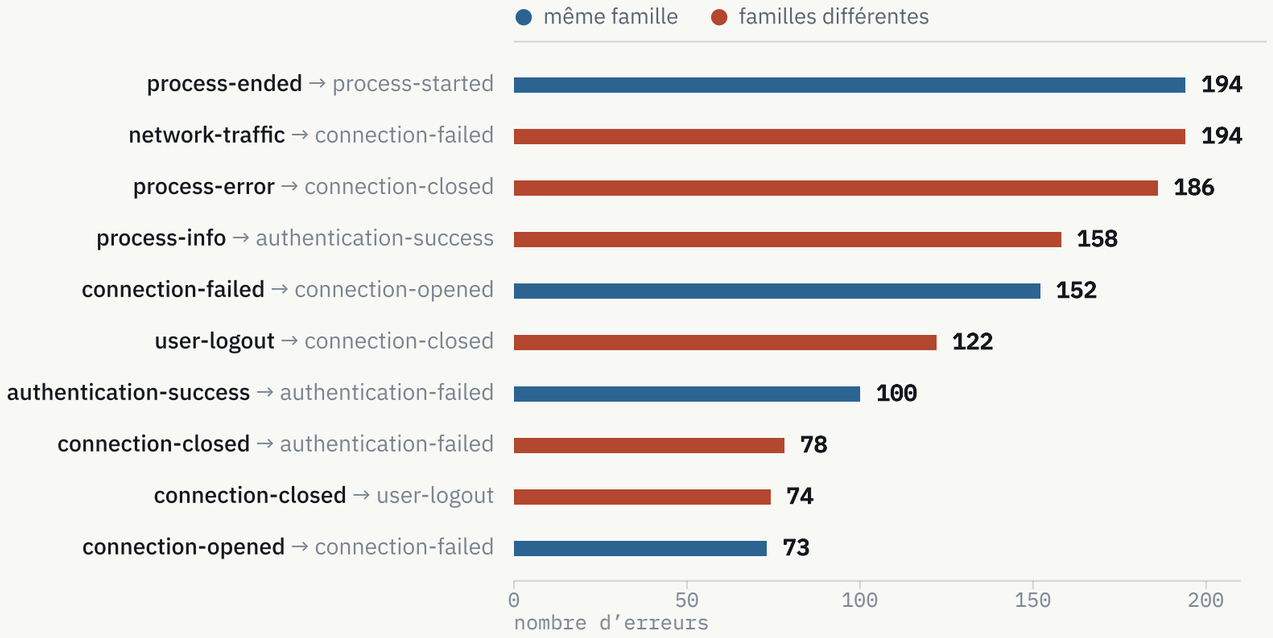
+2,0 pts
accuracy famille

Analyse des confusions

Le Macro-F1 masque des comportements très inégaux : certaines classes sont bien reconnues, d'autres ne sont jamais prédites.

TOP 10 DES CONFUSIONS — E1, MODÈLE HIÉRARCHIQUE

SIEVE_00 · 6 882 EXEMPLES



Quatre classes à F1 = 0

`network-traffic`
`process-ended`
`process-error`
`process-info`

Effondrement systématique

Pour ces quatre classes, 95 à 100 % des exemples de test partent vers une seule autre classe.

Erreurs intra-famille

`process-ended → process-started` reste dans la famille process : l'erreur fine préserve une information utile.

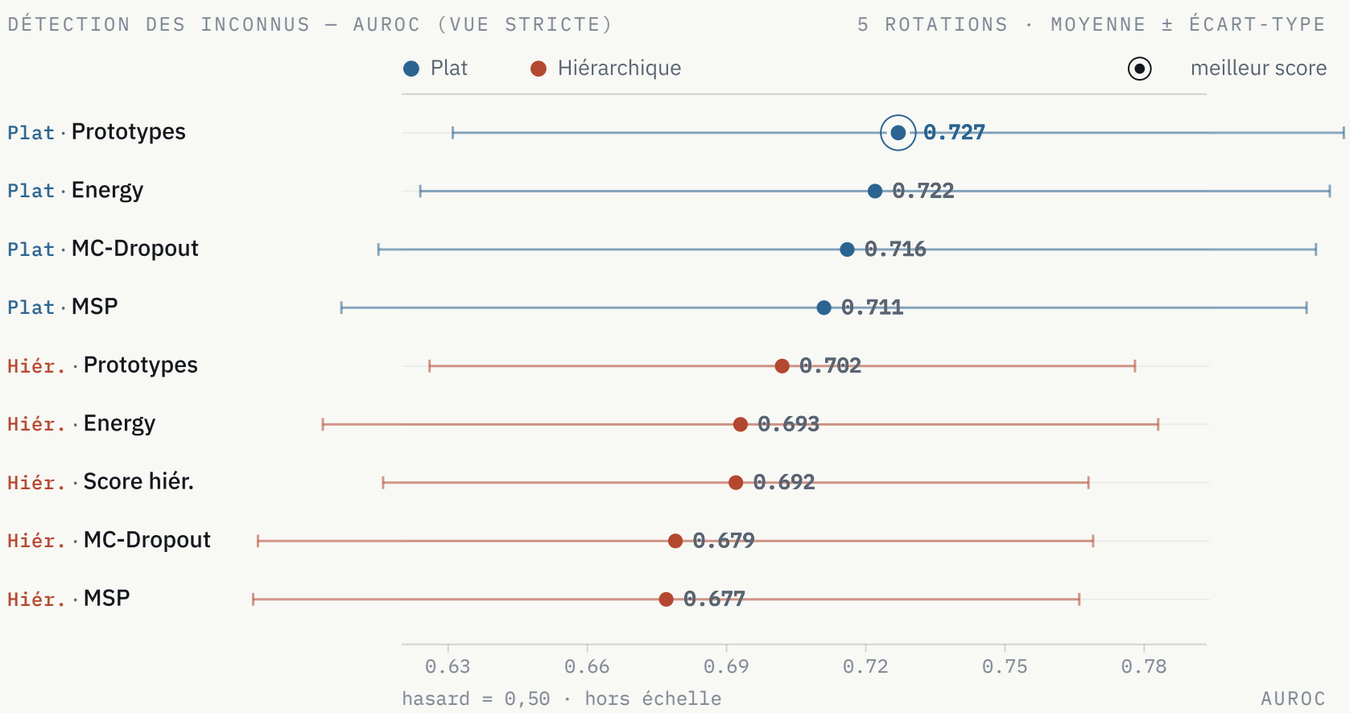
0,681
Macro-F1 sur 30 classes

0,786
moyenne hors 4 classes effondrées

4 / 30
classes jamais prédites

E2 — Détection des inconnus

Moyenne sur cinq rotations, vue stricte. La hiérarchie n'améliore pas la séparation entre connus et inconnus : le modèle plat avec prototypes reste devant.



Meilleur score

0,727 ± 0,096

Modèle plat · prototypes

Hiérarchique · prototypes : 0,702

Écart avec la cible

Le cahier des charges visait 95 % de détection. Une AUROC de 0,727 est utile mais imparfaite : 80 % des inconnus sont encore acceptés au seuil calibré.

Vue complète (filtrage asymétrique) : 0,810. La vue stricte est privilégiée.

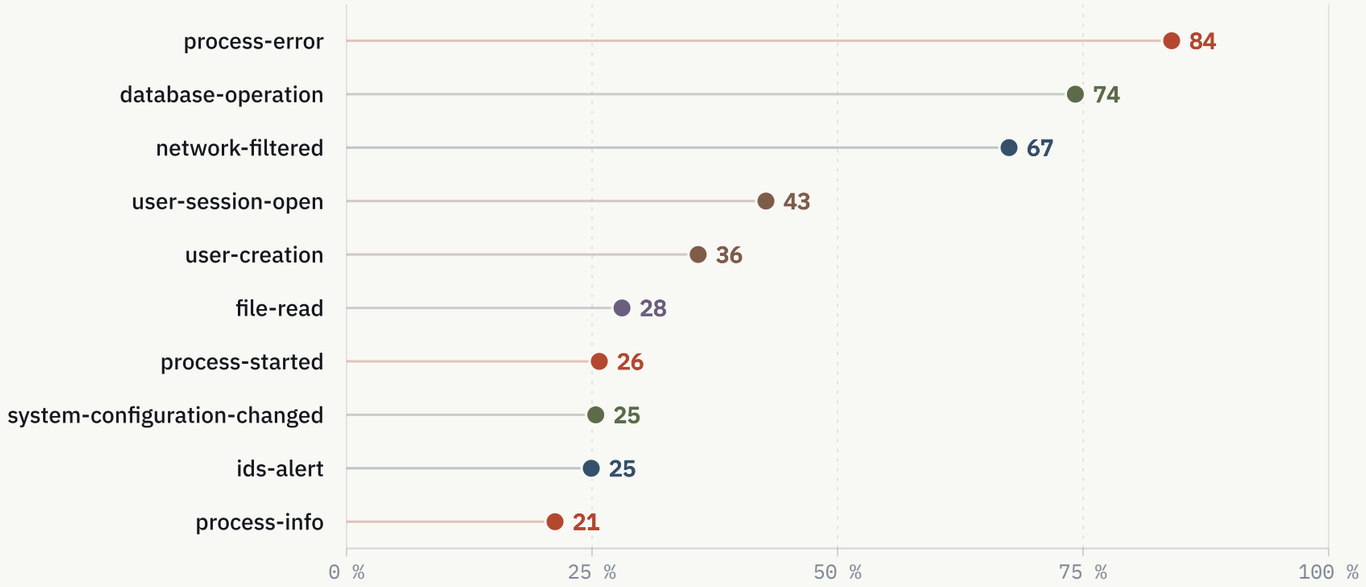
Prototypes : représentation moyenne par classe, similarité cosinus maximale.

Rejet par classe inconnue

Le score agrégé cache un comportement très inégal : certaines classes inconnues sont presque toujours rejetées, d'autres jamais.

TAUX DE REJET MOYEN — 10 CLASSES LES PLUS REJETÉES

MOYENNE SUR 9 COMBINAISONS



Les 20 autres classes ont un taux de rejet inférieur à 15 %.

Trois classes au-dessus de 50 %

process-error · 84 %
database-operation · 74 %
network-filtered · 67 %

19/30
sous 15 % de rejet

12 %
taux médian

Conséquence

Un déploiement réel devrait calibrer par famille ou par classe, et auditer les classes invisibles au détecteur.

Taux de rejet moyen sur les neuf combinaisons (plat / hiérarchique × cinq scores), tri décroissant.

E3 — Qualité de la hiérarchie

Sur les cinq rotations, les deux têtes sont d'accord dans 98,2 % des cas. La classe fine n'est pourtant pas meilleure que celle du modèle plat.

Modèle	Vue	Macro-F1	Acc. fine	Acc. famille	Cohérence
Plat	Toutes	0,725	76,5 %	83,7 %	–
Hiérarchique	Toutes	0,719	76,2 %	83,9 %	98,2 %
Plat	Stricte	0,589	64,6 %	76,0 %	–
Hiérarchique	Stricte	0,583	64,2 %	76,4 %	98,2 %

Cohérence brute

98,2 %

des prédictions fines appartiennent à la famille prédite.

Lecture

98 % de cohérence ne signifie pas 98 % de bonnes réponses : les deux têtes peuvent être d'accord et se tromper ensemble.

+0,2 pt
d'accuracy famille

−0,6 pt
de Macro-F1

0,28
d'ECE

`vrai : process-ended` — `prédit : process-started` famille process ✓ cohérent, mais faux

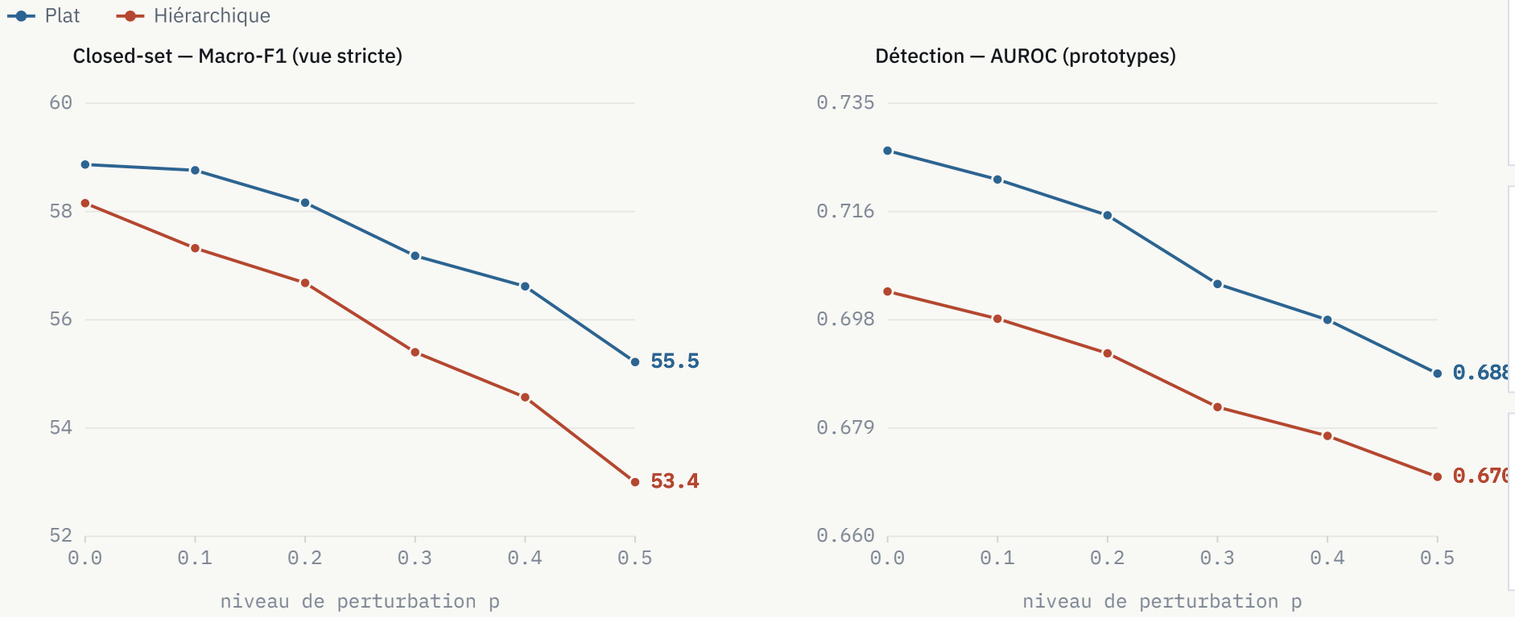
La hiérarchie structure la sortie, mais ne garantit pas une meilleure justesse fine.

E4 — Robustesse au bruit

De p = 0 à p = 0,5, les logs sont de plus en plus déformés. Les deux modèles se dégradent régulièrement, sans rupture brutale.

ROBUSTESSE AU BRUIT LEXICAL

SIEVE_00 → SIEVE_05



Macro-F1 · vue stricte

Plat : **58,9 → 55,5** (–3,4 pts)
Hiérarchique : **58,3 → 53,4** (–4,8 pts)

AUROC · prototypes

Plat : **0,727 → 0,688** (–0,039)
Hiérarchique : **0,702 → 0,670** (–0,032)

Similarité au propre

0,895 → 0,808 : la dégradation est réelle, mais progressive.

Le modèle reste au-dessus du hasard, mais la marge se réduit avec le bruit.

Synthèse des résultats

Le bilan est présenté par rapport aux quatre cibles du cahier des charges.

Cible	Résultat	Statut
F1 élevé sur le connu	0,681 en vue complète, 0,529 en vue stricte. Quatre classes à F1 = 0.	Partiel
95 % d'inconnus détectés	AUROC 0,727 ; 80 % des inconnus encore acceptés au seuil τ.	Non atteint
Famille exacte majoritaire	36 % sur les inconnus, contre 11 % au hasard.	Non atteint
Robustesse au bruit	Dégradation de 3 à 5 points entre p = 0 et p = 0,5.	Partiel

0
cible pleinement atteinte

2
partiellement atteintes

2
non atteintes

Acquis 01
Pipeline complet, 12 modèles, 42 minutes.

Acquis 02
Comparaison plat / hiérarchique, 5 scores, 5 rotations.

Acquis 03
Évaluation stricte, 19 classes séparées par template.

Ce qui reste à faire

Calibrer le seuil par famille, tester des scores plus robustes (Mahalanobis, OpenMax) et auditer les quatre classes effondrées.

> Le projet mesure précisément où la promesse tient et où elle ne tient pas.

Limites et conclusion

Limites et conclusion

Un projet honnête expose ses angles morts. Les limites ne annulent pas les résultats : elles disent ce qu'ils valent.

01 Limites du protocole

02 Conclusion

03 Perspectives

04 Questions

Limites

Chaque limite est reliée à son impact sur la lecture des résultats.

Données synthétiques

440 templates × Faker, 35 000 lignes par version.

Impact : les scores ne se transfèrent pas tels quels à des logs réels.

11 classes non strictes

Faute de groupes suffisants, une fuite résiduelle reste possible.

Impact : la vue stricte est plus prudente.

Filtrage asymétrique

La vue stricte filtre les connus, pas les inconnus : 0,727 contre 0,810.

Impact : les deux vues ne mesurent pas la même chose.

Inconnu simulé

Masquer des classes ne prouve pas la détection d'une nouveauté réelle.

Impact : le transfert CDS reste à exécuter.

Quatre classes effondrées

network-traffic, process-ended, process-error, process-info ne sont jamais prédites.

Impact : le Macro-F1 est sous-estimé.

Cinq rotations

IC95 larges, puissance limitée (p minimal ≈ 0,0625), ECE de 0,21 à 0,28.

Impact : les écarts doivent être lus avec prudence.

Priorité

Symétriser le filtrage strict et auditer les templates des quatre classes effondrées avant toute conclusion définitive.

Limite principale : l'open-set est simulé par retrait de classes, pas observé sur une dérive de production.

Conclusion

Le système produit une décision de rejet, mais il accepte encore 80 % des inconnus au seuil calibré. La hiérarchie apporte un gain fermé modéré ; elle n'apporte pas, seule, la capacité de reconnaître l'inconnu.

0,727
AUROC maximale

80 %
d'inconnus acceptés

36 %
de famille exacte

La hiérarchie aide le connu

+2,0 pts d'accuracy famille ; 0,702 d'AUROC contre 0,727 pour le plat.

Le score compte plus que l'architecture

Prototypes > Energy > MC-Dropout > MSP.

L'open-set reste ouvert

Trois classes portent l'essentiel du rejet ; le seuil global est trop grossier.

Le connu
72,0 % d'accuracy fine sur les classes apprises.

L'inconnu
20 % des inconnus rejetés au seuil calibré.

La famille
36 % de famille exacte sur les inconnus.

« Un système qui sait dire “je ne sais pas” vaut mieux qu'un système qui se trompe avec assurance. »

Perspectives

Cinq pistes, classées par coût croissant. Les deux premières sont réalisables dans le notebook actuel.

#	Piste	Objectif	Horizon
01	**Temperature scaling et seuil par famille**	Réduire l'ECE de 0,21–0,28 et éviter un seuil unique pour 30 classes.	Court terme
02	**Mahalanobis, OpenMax, ensembles**	Remplacer le seul MC-Dropout par des scores plus robustes en embedding.	Court terme
03	**Audit des quatre classes effondrées**	Vérifier les templates, les doublons et les conflits de labels.	Moyen terme
04	**Taxonomie validée par un expert SIEM**	Tester une ontologie métier plutôt qu'une construction de modélisation.	Moyen terme
05	**Transfert CDS et logs de production**	Sortir du synthétique, observer une vraie dérive, mesurer le coût analyste.	Long terme

Piste la plus prometteuse

Un score par famille, appris sur les classes connues, pour transformer la hiérarchie en signal d'inconnu plutôt qu'en simple contrainte de cohérence.

Court terme
Calibration et scores plus robustes.

Moyen terme
Audit des classes et validation métier.

Long terme
Transfert sur des logs de production.

Les deux premières pistes sont réalisables dans le notebook actuel.

Questions

Merci.

« Un système qui sait dire “je ne sais pas” vaut mieux qu'un système qui se trompe avec assurance. »

Présenté par

Mouhamadou Madeniyou SALL · Khadim MBAYE

Cours · Classe

NLP · DIC 3 IABD

Annexe A — Métriques

Métrique	Lecture
Macro-F1	Moyenne des F1 par classe. Pénalise les classes jamais prédites.
AUROC	Probabilité qu'un connu score plus haut qu'un inconnu.
AUPR	Aire précision-rappel, plus informative en cas de déséquilibre.
FPR@95TPR	Faux positifs quand on détecte 95 % des connus.
Accuracy fine	Proportion de classes fines correctement prédites.
Accuracy famille	Proportion de familles correctement prédites.

Métrique	Lecture
OSCR	Compromis entre reconnaissance du connu et rejet de l'inconnu.
ECE	Écart entre confiance annoncée et exactitude observée.
Distance taxonomique	0 = bonne classe ; 1 = même famille ; 2 = famille différente.
Rejet / acceptation	Part des connus rejetés à tort, part des inconnus acceptés à tort.
OSR-F1	F1 macro intégrant la classe « inconnu ».
AUPR-out	Précision-rappel sur les inconnus.

Lecture d'une AUROC

Une AUROC de 0,727 ne signifie pas « 72,7 % de détection » : elle indique qu'un connu a 72,7 % de chances de scorer plus haut qu'un inconnu. Le taux d'acceptation dépend du seuil.

Vue stricte

Les conclusions privilégient la vue stricte : 19 classes séparées par template, sans groupe partagé entre entraînement et test.

Les moyennes sont calculées sur les cinq rotations, avec écart-type.

Annexe B — Références

[1] Russkikh, Levshun, Ushakov. *Influence of Log Structure and Semantic Complexity on the Expediency of BERT-Based Models for Malicious Activity Detection*, RusAutoCon, 2026.

[2] Aghaei, Niu, Shadid, Al-Shaer. *SecureBERT: A Domain-Specific Language Model for Cybersecurity*, 2022.

[3] Bayer, Kuehn, Shanehsaz, Reuter. *CySecBERT: A Domain-Adapted Language Model for the Cybersecurity Domain*, arXiv, 2022.

[4] Guo, Yuan, Wu. *LogBERT: Log Anomaly Detection via BERT*, IJCNN, 2021.

[5] Vasan, Singh, Sharma, Yadav. *HLAST: Hierarchical Label-Aware Summarisation Transformer for Enhanced Cybersecurity Log Analysis*, 2025.

[6] Corbelle, Carneiro, Cacheda. *Semantic Hierarchical Classification Applied to Anomaly Detection Using System Logs with a BERT Model*, Applied Sciences, 2024.

[7] Pan, Wu. *Hierarchical Text Classification with LLMs via BERT-Based Semantic Modeling and Consistency Regularization*, 2025.

[8] Prasetyo, Rahmat, Sari. *Classification of Cyber Attack and Anomaly in Web Server Using Transformer and Transfer Learning*, IJEEEMI, 2025.

[9] Muslam et al. *SecMTL-BERT: A Multi-Task Transformer Framework for Unified Information Systems Security Text Intelligence*, 2026.

[10] Golde, Jedema, Krishnan, Le. *Hierarchical Text Classification with LLM-Refined Taxonomies*, arXiv, 2026.

NLP cyber
Comprend le texte, mais reste en monde fermé.

Hiérarchie
Structure la décision, sans mécanisme de rejet.

Open-set
Rejette l'inconnu, mais ignore la taxonomie.

> Revue complète : **etat-de-l'art/rapport.md**.

Annexe C — Glossaire

SIEM	Plateforme qui centralise et corrèle les logs de sécurité.
Template	Structure d'un log dont les valeurs varient.
Open-set	Des exemples peuvent appartenir à des classes jamais vues.
Prototype	Vecteur moyen représentatif d'une classe.
MC-Dropout	Incertitude estimée par plusieurs passes avec dropout.
ECE	Écart moyen entre confiance et exactitude.
AUROC	Capacité d'un score à ordonner connus et inconnus.
Fuite de template	Variantes d'un même template séparées entre train et test.
Log	Enregistrement textuel d'un événement système.
Closed-set	Toutes les classes sont connues à l'entraînement.
OOD	Hors distribution : éloigné de ce que le modèle a appris.
Calibration	Ajustement du seuil sur validation.
OSCR	Métrique combinant reconnaissance et rejet.
SPICE	Perturbation lexicale contrôlée des versions SIEVE.
Famille	Groupe parent d'une classe fine.
Fine-tuning	Réentraînement supervisé d'un modèle pré-entraîné.

> Fin de la présentation.